

Otimização de Sistemas

Prof. Sandro Jerônimo de Almeida, PhD.



Programação Não Linear

Fundamentos



Programação Linear vs Não-Linear

- Os modelos empregados em Programação Linear são, como o próprio nome diz, lineares (tanto a função-objetivo quanto as restrições)
- Essa é uma das maiores restrições impostas sobre um modelo de Programação
- Em grande parte das aplicações, modelos lineares refletem apenas aproximações dos modelos reais
- Fenômenos físicos ou econômicos são geralmente melhor representados por modelos não-lineares




Categorias de Não-Linearidade

- Relações observadas empiricamente, tais como variações não-proporcionais em custos, resultados de processos e características de qualidade.
 - > Simplesmente cortar “o mais barato” aumenta o lucro?
- Relações deduzidas estruturalmente, que englobam fenômenos físicos, deduzidos matematicamente e regras administrativas



Exemplo de Não-Linearidade



Programação Não Linear

Formulação/Modelo

- Variáveis de decisão

$$x = (x_1, x_2, x_3, \dots, x_n)$$

- Maximizar $f(x)$

Sujeito a:

$$g_i(x) \leq b_i, \text{ para } i = 1, 2, \dots, m$$

$$\text{e } x \geq 0$$

- $f(x)$ e/ou $g_i(x)$ são funções não lineares

Problema pode ser de minimização



- Minimizar $f(x)$




- $g_i(x) \geq b_i$



Exemplo de Modelo de PPNL

Restrição não linear

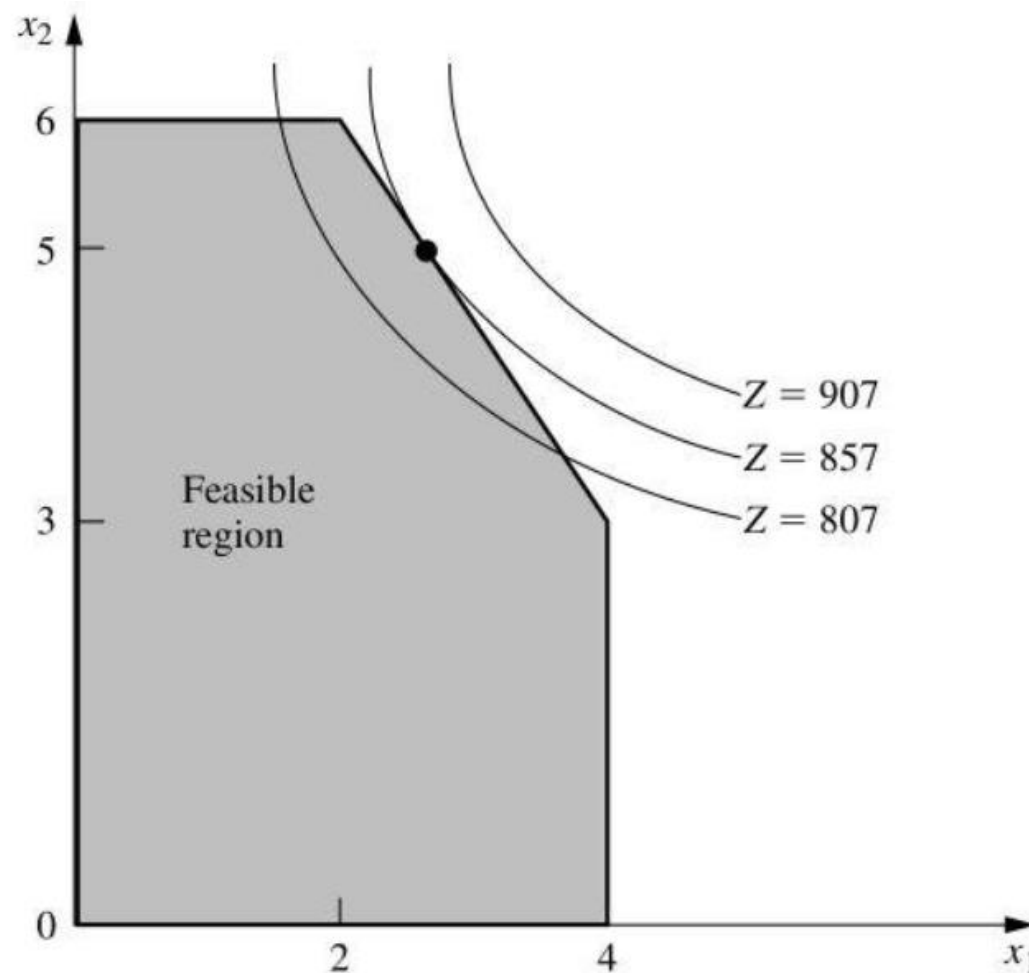
Maximize $Z = 3x_1 + 5x_2$,
subject to $x_1 \leq 4$
 $9x_1^2 + 5x_2^2 \leq 216$
and $x_1 \geq 0, \quad x_2 \geq 0$



Exemplo de Modelo de PPNL

Função objetivo não linear


Maximize $Z = 126x_1 - 9x_1^2 + 182x_2 - 13x_2^2$,
subject to $x_1 \leq 4$
 $2x_2 \leq 12$
 $3x_1 + 2x_2 \leq 18$
and $x_1 \geq 0, x_2 \geq 0$



Exemplo de Modelo de PPNL

Função objetivo não linear


$$\begin{array}{ll}\text{Maximize} & Z = 54x_1 - 9x_1^2 + 78x_2 - 13x_2^2, \\ \text{subject to} & x_1 \leq 4 \\ & 2x_2 \leq 12 \\ & 3x_1 + 2x_2 \leq 18 \\ \text{and} & x_1 \geq 0, \quad x_2 \geq 0\end{array}$$



Programação Não Linear

Tipos de problemas e métodos

- Modelos sem restrições – Otimização Irrestrita
- Modelos com restrições
- Modelos com múltiplos pontos de mínimo/máximo



Programação Não Linear

Tipos de problemas e métodos


- Modelos sem restrições – Otimização Irrestrita
 - Modelos com restrições
 - Modelos com múltiplos pontos de mínimo/máximo
-
- **Importante:** o principal conceito envolvido em Programação Não-Linear é o de taxa de variação
⇒ derivadas e gradientes



Local vs. Global Optima

Def'n: Let x be a feasible solution, then

- x is a global max if $f(x) \geq f(y)$ for every feasible y .
- x is a local max if $f(x) \geq f(y)$ for every feasible y sufficiently close to x (i.e., $x_j - \epsilon \leq y_j \leq x_j + \epsilon$ for all j and some small ϵ).




There may be several locally optimal solutions.

When is a locally optimal solution also globally optimal?

- We are minimizing. The objective function is convex. The feasible region is convex.

Convexity and Extreme Points



We say that a set S is *convex*, if for every two points x and y in S , and for every real number λ in $[0,1]$, $\lambda x + (1-\lambda)y \in S$.






The feasible region of a linear program is convex.

We say that an element $w \in S$ is an *extreme point* (vertex, corner point), if w is not the midpoint of any line segment contained in S .

Recognizing convex feasible regions

- If all constraints are linear, then the feasible region is convex
- The intersection of convex regions is convex
- If for all feasible x and y , the midpoint of x and y is feasible, then the region is convex (except in totally non-realistic examples.)

Which are convex?




Exercício – Modelagem PPLN

Problema de Localização

- O Gerente de Projetos de Infraestrutura de Redes de uma Universidade tem que instalar um Roteador Wireless para atender a três prédios dentro do campus (usuários com notebooks e smartphones). Para uma boa qualidade de serviço, o roteador não pode ficar a mais de 100 metros do centro de cada bloco. Considere as seguintes localizações/coordenadas

Prédio	X	Y
Prédio I	-50	100
Prédio J	20	10
Prédio L	100	50

- Apresente um modelo de otimização para determinar a localização ótima do roteador



Exercício – Problema de Localização

Dados

```
data;  
  
set N := PredioI PredioJ PredioL;  
  
#Localizações  
param:      x      y :=  
  PredioI   -50 100  
  PredioJ    20 10  
  PredioL   100 50;  
  
param d_min := 100;
```

ProblemaLocalizacao.dat

Comandos

- 1) ampl: model ProblemaLocalizacao.mod
- 2) ampl: data ProblemaLocalizacao.dat
- 3) ampl: solve
- 4) ampl: display x_r, y_r;

Modelo

```
set N;  
  
param d_min; # Distância Mínima  
param x {i in N}; # vetor de posicoes x  
param y {i in N}; # vetor de posicoes y  
  
#Variáveis de decisao  
var x_r >=0;  
var y_r >=0;  
  
#Minimizar a soma das distâncias euclidianas  
minimize distancias:  
sum {i in N} sqrt((x[i]- x_r)^2 + (y[i]- y_r)^2);  
  
#distancia minima para cada prédio  
subject to distancia {i in N}:  
sqrt((x[i]- x_r)^2 + (y[i]- y_r)^2) <= d_min;
```

ProblemaLocalizacao.mod

Resposta

19 iterations, objective 201.0122877
x_r = 23.3923 | y_r = 32.0767

Least Square Problem

Applications in model constructions, statistics (e.g., linear regression), neural networks, etc.

We consider a linear measurement model, i.e., we stipulate that an (output) quantity of interest $y \in \mathbb{R}$ can be expressed as a linear function $y \approx a^T x$ of input $a \in \mathbb{R}^n$ and model parameters $x \in \mathbb{R}^n$. Our goal is to find the vector of parameters x which provide the “best fit” for the available set of input-output pairs (a_i, y_i) , $i = 1, \dots, m$. If “fit” is measured by sum of squared errors between estimated and measured outputs, solution to the following optimization problem

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \sum_{i=1}^m (v_i)^2 \\ \text{s.t.} \quad & v_i = y_i - a_i^T x, \quad i = 1, \dots, m \end{aligned} \quad = \min_{x \in \mathbb{R}^n} \sum_{i=1}^m (y_i - a_i^T x)^2 = \min_{x \in \mathbb{R}^n} \|Ax - y\|_2^2,$$

provides the best fit. Here, A is the matrix with rows a_i^T .

Markowitz Portfolio Optimization Model

Suppose one has the opportunity to invest in n assets. Their future returns are represented by random variables, R_1, \dots, R_n , whose expected values and covariances, $E[R_i]$, $i = 1, \dots, n$ and $\text{Cov}(R_i, R_j)$, $i, j = 1, \dots, n$, respectively, can be estimated based on historical data and, possibly, other considerations. At least one of these assets is a risk-free asset.

Suppose x_i , $i = 1, \dots, n$, are the fractions of your wealth allocated to each of the assets (that is, $x_i \geq 0$ and $\sum_{i=1}^n x_i = 1$). The return of the resulting portfolio is a random variable $\sum_{i=1}^n x_i R_i$ with mean $\sum_{i=1}^n x_i E[R_i]$ and variance $\sum_{i=1}^n \sum_{j=1}^n x_i x_j \text{Cov}(R_i, R_j)$. A portfolio is usually chosen to optimize some measure of a tradeoff between the expected return and the risk, such as

$$\begin{aligned} \max \quad & \sum_{i=1}^n x_i E[R_i] - \mu \sum_{i=1}^n \sum_{j=1}^n x_i x_j \text{Cov}(R_i, R_j) \\ \text{s.t.} \quad & \sum_{i=1}^n x_i = 1 \\ & x_i \geq 0, \end{aligned}$$

where $\mu > 0$ is a (fixed) parameter reflecting the investor's preferences in the above tradeoff. Since it is hard to assess anybody's value of μ , the above problem can (and should) be solved for a variety of values of μ , thus generating a variety of portfolios on the *efficient frontier*.