

Otimização de Sistemas

Prof. Sandro Jerônimo de Almeida, PhD.



Programação Não Linear

Otimização Irrestrita

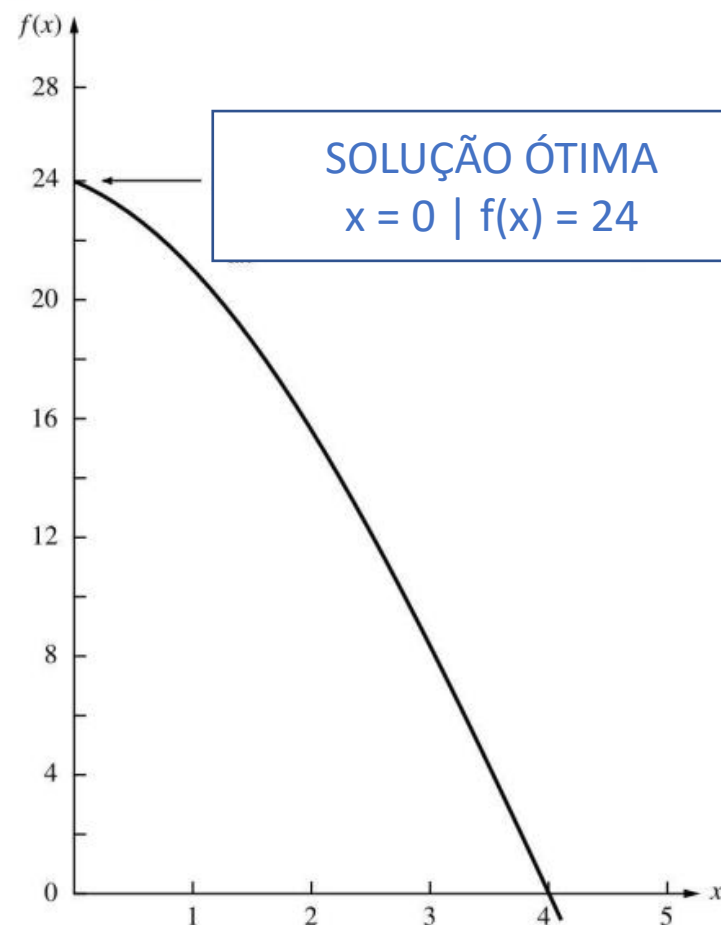


Programação Não Linear

Otimização Irrestrita

Maximize $f(x) = 24 - 2x - x^2$,
subject to $x \geq 0$.

para $x_j \geq 0$



Programação Não Linear


Otimização Irrestrita – Um método Simples

Consiste nos seguintes passos:

- 1) “chutar” 3 pontos (a, b, c) .
- 2) Escolher um ponto x entre a e b ou entre b e c .

Supondo que escolhemos entre b e c :

- 3) Se $f(b) < f(x) \Rightarrow$ 3 novos pontos são (a, b, x) .
- 4) Senão \Rightarrow 3 novos pontos são (b, x, c) .
- 5) Repetir processo até precisão desejada.



Programação Não Linear

Otimização Irrestrita – Um método Simples

Problema do Método apresentado


- Extremamente dependente da inicialização (problema comum aos Métodos determinísticos).
- Função precisa ser avaliada em muitos pontos \Rightarrow alto custo computacional.
- Informação da derivada da função permite alcançar o extremo com menor número de avaliações da função \Rightarrow melhor eficiência computacional.



Programação Não Linear

Otimização Irrestrita – Exemplo


- De uma longa folha de metal de 30 cm de largura deve-se fazer uma calha dobrando as bordas perpendicularmente à folha. Quantos centímetros devem ser dobrados de cada lado de modo que a calha tenha capacidade máxima ?



Programação Não Linear

Otimização Irrestrita – Exemplo

- De uma longa folha de metal de 30 cm de largura deve-se fazer uma calha dobrando as bordas perpendicularmente à folha. Quantos centímetros devem ser dobrados de cada lado de modo que a calha tenha capacidade máxima ?




- Quanto deve medir x para que a calha tenha capacidade máxima ?

Programação Não Linear

Otimização Irrestrita – Exemplo

- A capacidade de escoamento de água da calha é, formalmente, a vazão
- $Q(A, v) = A \cdot v$
 - $Q(A, v)$ é a vazão (cm^3/s);
 - A é a área da seção (cm^2); e
 - v é a velocidade do fluido (cm/s).
- Supondo v constante, a vazão torna-se diretamente proporcional à área da seção. Portanto, maximizando A implica em maximizar $Q(A, v)$.



Maximizar

$$f(x) = x \cdot (30 - 2x) = 30x - 2x^2$$

Sujeito a: $x > 0$

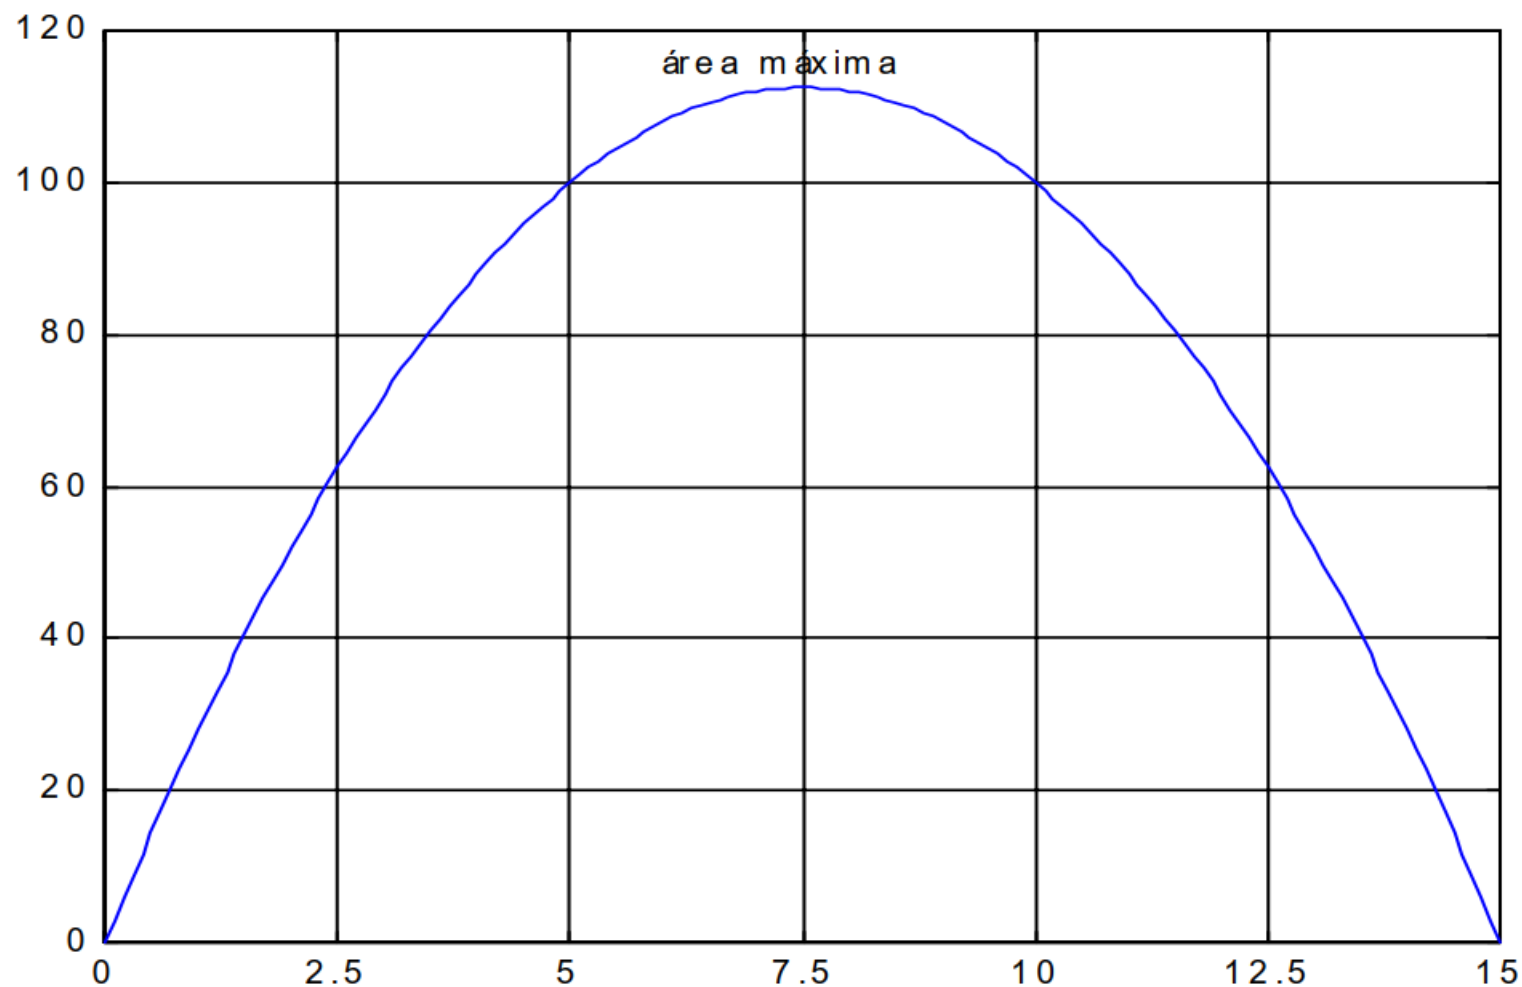
Programação Não Linear

Otimização Irrestrita – Exemplo

Maximizar

$$f(x) = x \cdot (30 - 2x) = 30x - 2x^2$$

Sujeito a: $x > 0$



Programação Não Linear

Derivada e Gradiente

- Problema com uma variável (1-D): derivada fornece a informação da taxa de variação da função: $f'(x)$
- Problema com N variáveis (N-D): o vetor gradiente fornece a direção da maior taxa de variação da função.

$$\nabla f = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \frac{\partial f}{\partial x_3}, \dots, \frac{\partial f}{\partial x_n} \right]$$




Programação Não Linear

Vetor Gradiente - Definição

O gradiente de uma função f , denotado por ∇f ou **grad** f , é a função vetorial cujas componentes são as derivadas parciais, ou seja,

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right).$$

Exemplo: $f(x,y) = x^2 + xy + y^2$.



$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 2x + y \\ 2y + x \end{bmatrix}$$



2 elementos
no vetor

Programação Não Linear

Exercício – Vetor Gradiente

- Determine o vetor gradiente de $f(x, y) = x^3 + x^2y^3 - 2y^2$



Programação Não Linear

Exercício – Vetor Gradiente

- Determine o vetor gradiente de $f(x, y) = x^3 + x^2y^3 - 2y^2$
 - Derivadas parciais
- Vetor gradiente

$$\frac{\partial f}{\partial x} = 3x^2 + 2xy^3$$

$$\frac{\partial f}{\partial y} = 3x^2y^2 - 4y$$

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 3x^2 + 2xy^3 \\ 3x^2y^2 - 4y \end{bmatrix}$$



Programação Não Linear

Método do Gradiente (ou Cauchy ou método descendente)

- Método consiste em procurar o máximo (ou mínimo) na direção de maior taxa de crescimento (ou decrescimento) da Função Objetivo a partir de uma solução (ponto) inicial X_0
- Maximização: $X_{i+1} = X_i + t \cdot \nabla f(X_i)$
- Minimização: $X_{i+1} = X_i - t \cdot \nabla f(X_i)$
- t é o “tamanho do passo” | i é o número da iteração
- $x = (x_1, x_2, x_3, \dots, x_n)$



1789 – 1857

Programação Não Linear

Resolvendo o problema da calha com método gradiente (1D)

Maximizar $f(x) = x \cdot (30 - 2x) = 30x - 2x^2$

Sujeito a: $x > 0$

Teremos:

$$\nabla f(x) = f'(x) = 30 - 4x$$

$$X_{i+1} = X_i + t \cdot \nabla f(X_i)$$

$$\text{Resíduo} = |X_{i+1} - X_i|$$

Assumindo: $t = 0.1$ | Ponto inicial: $x_0 = -3$

Condição de parada: Resíduo ≤ 0.0007



Programação Não Linear

Resolvendo o problema da calha com método gradiente

Maximizar $f(x) = x \cdot (30 - 2x) = 30x - 2x^2$

Sujeito a: $x > 0$

Assumindo: $t = 0.1$ | Ponto inicial: $x_0 = -3$

Condição de parada: Resíduo ≤ 0.0007

Teremos:

$$\nabla f(x) = f'(x) = 30 - 4x$$

$$X_{i+1} = X_i + t \cdot \nabla f(X_i)$$

$$\text{Resíduo} = |X_{i+1} - X_i|$$

1ª Iteração $x_0 = -3$ $x_1 = -3 + 0.1(30 - 4(-3)) = 1.2$ Resíduo = 4.2	2ª iteração $x_1 = 1.2$ $x_2 =$

Programação Não Linear

Resolvendo o problema da calha com método gradiente

Maximizar $f(x) = x.(30-2x) = 30x-2x^2$

Sujeito a: $x > 0$

Assumindo: $t = 0.1$ | Ponto inicial: $x_0 = -3$

Condição de parada: $\text{Resíduo} \leq 0.0007$

Teremos:

$$\nabla f(x) = f'(x) = 30 - 4x$$

$$X_{i+1} = X_i + t.\nabla f(X_i)$$

$$\text{Resíduo} = |X_{i+1} - X_i|$$

1° Iteração $x_0 = -3$ $x_1 = -3 + 0.1(30 - 4(-3)) = 1.2$ Resíduo = 4.2	2° iteração $x_1 = 1.2$ $x_2 = 1.2 + 0.1(30 - 4(1.2)) = 3.72$ Resíduo = 2.52
3° iteração $x_2 = 3.72$ $x_3 =$	

Programação Não Linear

Resolvendo o problema da calha com método gradiente

Maximizar $f(x) = x.(30-2x) = 30x-2x^2$

Sujeito a: $x > 0$

Assumindo: $t = 0.1$ | Ponto inicial: $x_0 = -3$

Condição de parada: Resíduo ≤ 0.0007

Teremos:

$$\nabla f(x) = f'(x) = 30 - 4x$$

$$X_{i+1} = X_i + t.\nabla f(X_i)$$

$$\text{Resíduo} = |X_{i+1} - X_i|$$

1° Iteração $x_0 = -3$ $x_1 = -3 + 0.1(30 - 4(-3)) = 1.2$ Resíduo = 4.2	2° iteração $x_1 = 1.2$ $x_2 = 1.2 + 0.1(30 - 4(1.2)) = 3.72$ Resíduo = 2.52
3° iteração $x_2 = 3.72$ $x_3 = 3.72 + 0.1(30 - 4(3.72))$ = 5.232 Resíduo = 1.512	19° iteração $x_{18} = 7.4982$ $x_{19} =$

Programação Não Linear

Resolvendo o problema da calha com método gradiente

Maximizar $f(x) = x.(30-2x) = 30x-2x^2$

Sujeito a: $x > 0$

Assumindo: $t = 0.1$ | Ponto inicial: $x_0 = -3$

Condição de parada: $\text{Resíduo} \leq 0.0007$

Teremos:

$$\nabla f(x) = f'(x) = 30 - 4x$$

$$X_{i+1} = X_i + t \cdot \nabla f(X_i)$$

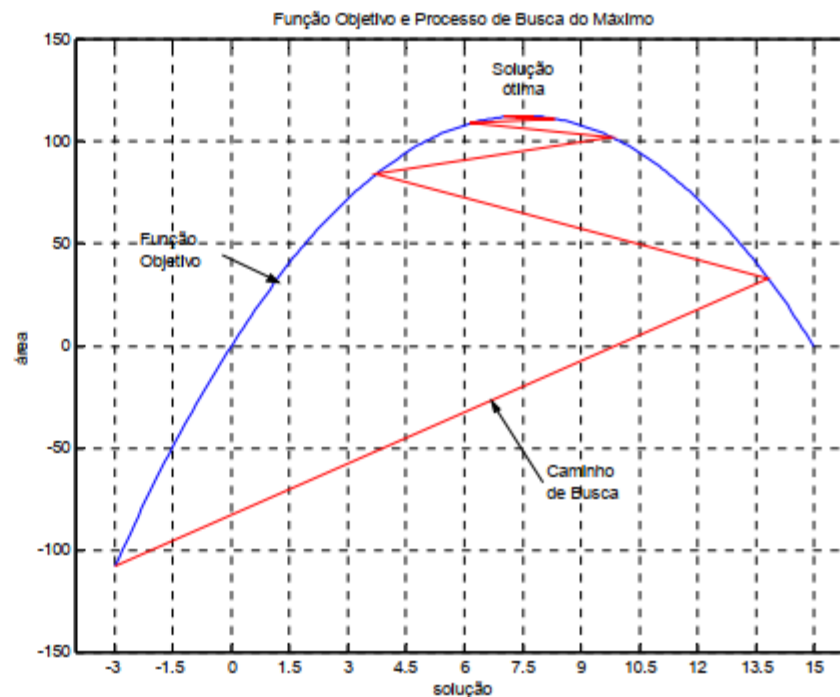
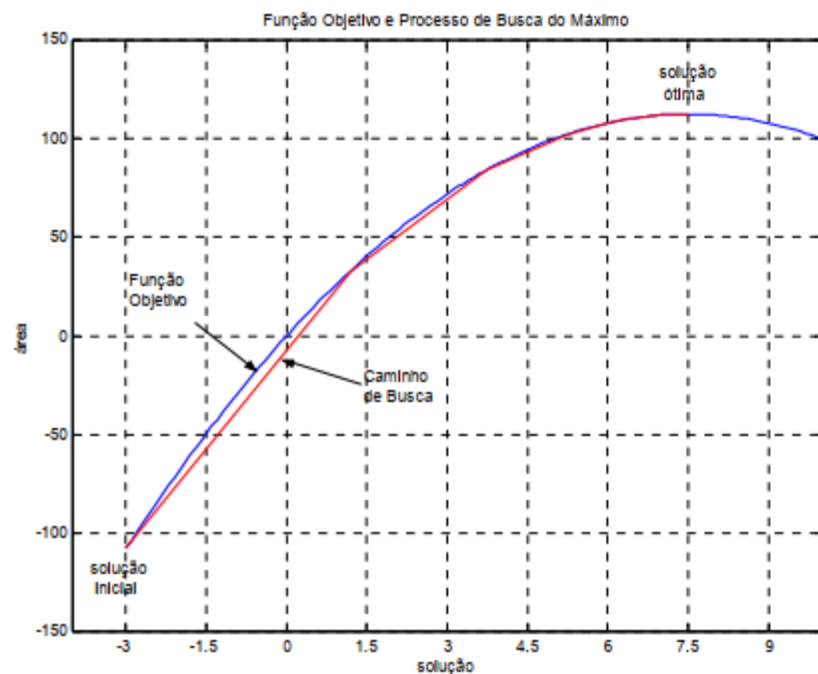
$$\text{Resíduo} = |X_{i+1} - X_i|$$

<p>1° Iteração</p> <p>$x_0 = -3$</p> <p>$x_1 = -3 + 0.1(30 - 4(-3)) = 1.2$</p> <p>Resíduo = 4.2</p>	<p>2° iteração</p> <p>$x_1 = 1.2$</p> <p>$x_2 = 1.2 + 0.1(30 - 4(1.2)) = 3.72$</p> <p>Resíduo = 2.52</p>
<p>3° iteração</p> <p>$x_2 = 3.72$</p> <p>$x_3 = 3.72 + 0.1(30 - 4(3.72))$ $= 5.232$</p> <p>Resíduo = 1.512</p>	<p>19° iteração</p> <p>$x_{18} = 7.4982$</p> <p>$x_{19} = 7.4982 + 0.1(30 - 4(7.4982))$ $= 7.4989$</p> <p>Resíduo = 0.0007</p>

Programação Não Linear

Resolvendo o problema da calha com método gradiente

O gráfico da esquerda mostra o “caminho de busca (trajetória)” da solução ótima realizada pelo algoritmo para $t = 0.1$ e o da direita para $t = 0.4$.



Exercício

- Faça a 1ª iteração do método gradiente na busca da solução do seguinte problema: $Max f(x,y) = 5x^2 + 5y^2 + xy + 2y$. Assuma o ponto inicial (3,3) e $t = 0,1$



Exercício

- Faça a 1ª iteração do método gradiente na busca da solução do seguinte problema: $Max f(x,y) = 5x^2 + 5y^2 + xy + 2y$. Assuma o ponto inicial (3,3) e $t = 0,1$
- *Vetor gradiente (formado pelas derivadas parciais de f)*

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 10x + y \\ 10y + x + 2 \end{bmatrix}$$

- Aplicando: $X_{i+1} = X_i + t \cdot \nabla f(X_i)$

$$\begin{bmatrix} x_{i+1} \\ y_{i+1} \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} + 0,1 \begin{bmatrix} 10x + y \\ 10y + x + 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} + 0,1 \begin{bmatrix} 33 \\ 35 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} + \begin{bmatrix} 3,3 \\ 3,5 \end{bmatrix} = \begin{bmatrix} 6,3 \\ 6,5 \end{bmatrix}$$

- Resíduo: distância euclidiana entre (3,3) e (6.3, 6.5)

Programação Não Linear

Método gradiente – Existe um tamanho de t ótimo?

- A solução ótima será alcançada mais rapidamente quanto menos a função objetivo for avaliada

- Artifício: aplicar o gradiente para achar o tamanho de t

$Z(t) = x + t \cdot \nabla f(x) = x + t \cdot f'(x)$ - substituindo $Z(t)$ em $f(x)$, teremos:

$$g(t) = f(Z(t))$$

- Igualando a derivada de $g(t)$ (em relação a t) a zero ($g'(t)=0$) e então resolvendo para t , encontra-se uma função que descreve os valores ótimos de t para cada solução x



Programação Não Linear

Resolvendo o problema da calha com t ótimo

- $Z(t) = x + t \cdot \nabla f(x) = x + t \cdot f'(x)$

$$Z(t) = x + t(30 - 4x)$$

- Substituindo $Z(t)$ em f , teremos:

$$g(t) = f(Z(t)) = 30x + 900t - 240xt - 2x^2 + 16x^2t + 480xt^2 - 1800t^2 - 32x^2t^2$$

$$g'(t) = 900 - 240x + 16x^2 + 960xt - 3600t - 64x^2t$$

$$t = \frac{-16x^2 + 240x - 900}{960x - 3600 - 64x^2} = \begin{cases} 0.25 \forall x \in \mathbb{R} \neq 7.5 \\ \notin t \text{ para } x = 7.5 \end{cases}$$

Neste caso específico, o valor de t será constante, ou seja, $t=0.25$ valerá para qualquer x diferente de 7.5

1º Iteração

$$x_0 = -3$$

$$x_1 = -3 + 0.25(30 - 4(-3)) \\ = 7.5$$

Programação Não Linear

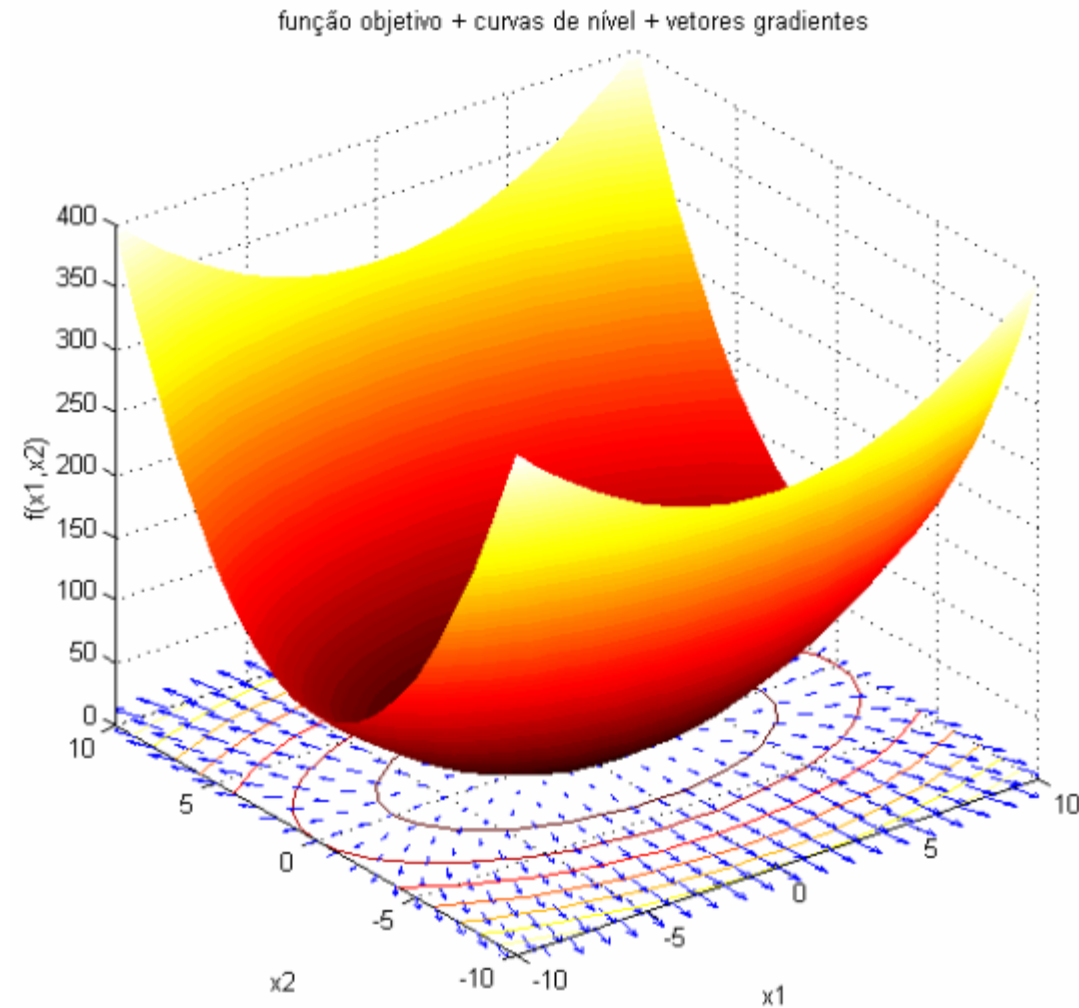
Exemplo 2D

$$\text{Min} \quad f(\mathbf{X}) = x_1^2 + 3x_2^2$$

Vetor Gradiente / Derivadas parciais

$$\nabla f(\mathbf{X}) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix}$$

$$\nabla f(\mathbf{X}) = \begin{bmatrix} 2x_1 \\ 6x_2 \end{bmatrix}$$



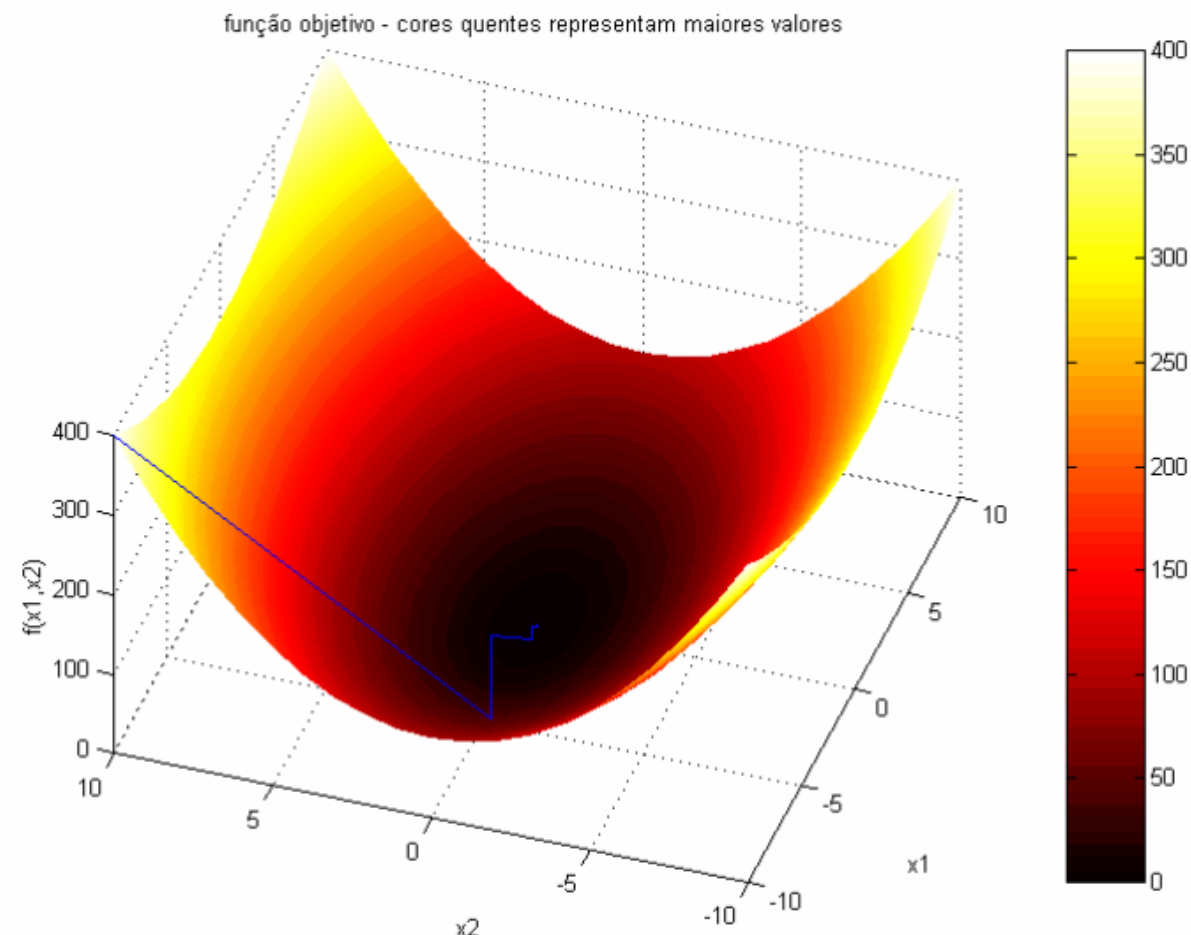

Programação Não Linear

Exemplo 2D – Busca a partir do ponto (-10, 10)

$$\text{Min} \quad f(X) = x_1^2 + 3x_2^2$$

$$\nabla f(X) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix}$$

$$\nabla f(X) = \begin{bmatrix} 2x_1 \\ 6x_2 \end{bmatrix}$$



Programação Não Linear

$$\text{resíduo} = \sqrt{(x_1(i+1) - x_1(i))^2 + (x_2(i+1) - x_2(i))^2}$$

Resolvendo o exemplo 2D com t ótimo

$$\begin{bmatrix} x_1(i+1) \\ x_2(i+1) \end{bmatrix} = \begin{bmatrix} x_1(i) \\ x_2(i) \end{bmatrix} - t \cdot \begin{bmatrix} 2x_1(i) \\ 6x_2(i) \end{bmatrix}$$

Fazendo

$$z(t) = \begin{bmatrix} x_1(i+1) \\ x_2(i+1) \end{bmatrix} \quad \text{e} \quad g(t) = f(z(t))$$

$$g(t) = f(z(t)) = (1 - 2t)^2 x_1^2 + 3(1 - 6t)^2 x_2^2$$

$$g'(t) = 2(1 - 2t)x_1^2(-2) + 6(1 - 6t)x_2^2(-6) = 0$$

Teremos:
$$t = \frac{x_1^2 + 9x_2^2}{2x_1^2 + 54x_2^2}$$

Neste problema para cada valor de x e y poderemos ter um t .

x_1	x_2	tamanho passo	iteração
-10.0000	10.0000	-	0
-6.4286	-0.7143	0.1786	1
-1.0714	1.0714	0.4167	2
-0.6888	-0.0765	0.1786	3
-0.1148	0.1148	0.4167	4
-0.0738	-0.0082	0.1786	5
-0.0123	0.0123	0.4167	6
-0.0079	-0.0009	0.1786	7
-0.0013	0.0013	0.4167	8
-0.0008	-0.0001	0.1786	9
-0.0001	0.0001	0.4167	10

Exercício

- Faça a 1ª iteração do método gradiente na busca da solução do seguinte problema: $Max f(x,y) = 5x^2 + 5y^2 - xy - 2y$. Assuma o ponto inicial (0,0) e *determine o t ideal para essa iteração.*



Exercício

- 1° iteração do método gradiente na busca da solução do seguinte problema: $Max f(x,y) = 5x^2 + 5y^2 - xy - 2y$. Assumindo o ponto inicial $(0,0)$ e *calculando o t ideal*

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 10x - y \\ 10y - x - 2 \end{bmatrix}$$

$$\nabla f(0,0) = \begin{bmatrix} 0 \\ -2 \end{bmatrix}$$

$$Z(t) = \begin{bmatrix} 0 + t(0) \\ = +t(-2) \end{bmatrix} = \begin{bmatrix} 0 \\ -2t \end{bmatrix}$$

$$f(Z(t)) = f(0, -2t) = 20t^2 + 4t$$

Sendo $g(t) = f(Z(t))$ e derivando $g(t)$

$$g'(t) = 40t + 4 = 0$$

$$t = -\frac{1}{10}$$

$$\begin{bmatrix} x_{i+1} \\ y_{i+1} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \frac{1}{10} \begin{bmatrix} 0 \\ -2 \end{bmatrix} = \begin{bmatrix} 0, \frac{1}{5} \end{bmatrix}$$

Exercício

- Faça a 2ª iteração do método gradiente na busca da solução do seguinte problema: $\text{Max } f(x,y) = 5x^2 + 5y^2 - xy - 2y$. Assuma o ponto anterior $\left[0, \frac{1}{5}\right]$ e *determine o t ideal*. Verifique se o t se mantém o mesmo da iteração anterior



Exercício

- 2ª iteração do método gradiente na busca da solução do seguinte problema: $\text{Max } f(x,y) = 5x^2 + 5y^2 - xy - 2y$. Assumindo o ponto anterior $\left[0, \frac{1}{5}\right]$ e calculando o t ideal

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 10x - y \\ 10y - x - 2 \end{bmatrix}$$

$$\nabla f\left(0, \frac{1}{5}\right) = \begin{bmatrix} -\frac{1}{5} \\ 0 \end{bmatrix}$$

$$\begin{aligned} Z(t) &= \left[0 + t\left(-\frac{1}{5}\right), \frac{1}{5} + t(0) \right] \\ &= \begin{bmatrix} -\frac{t}{5} \\ \frac{1}{5} \end{bmatrix} \end{aligned}$$

$$f(Z(t)) = f\left(-\frac{t}{5}, \frac{1}{5}\right) = \frac{1}{5} \left(t^2 + \frac{t}{5} - 1 \right)$$

Sendo $g(t) = f(Z(t))$ e derivando $g(t)$

$$g'(t) = \frac{1}{5} \left(2t + \frac{1}{5} \right) = 0 \mid t = -\frac{1}{10}$$

$$\begin{bmatrix} x_{i+1} \\ y_{i+1} \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{1}{5} \end{bmatrix} - \frac{1}{10} \begin{bmatrix} -\frac{1}{5} \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{50} \\ \frac{1}{5} \end{bmatrix}$$

Programação Não Linear

Método de Newton (ou Newton-Raphson)

- Desenvolvido por Isaac Newton e Joseph Raphson

- Em Cálculo

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

Encontra raízes de uma função diferenciável


- Em Otimização:

(minimização)

$$x_{k+1} = x_k - \underbrace{\frac{f'(x_k)}{f''(x_k)}}_{\text{Passo } t}$$

Encontra raízes de uma função derivada (f') usando a derivada 2° (f'')

- Dependendo da inicialização pode não chegar ao resultado (não há garantia de solução)



1642 – 1727



Programação Não Linear


Método de Newton (ou Newton-Raphson)

- Exemplo: $f(x) = x^2$ | Vamos assumir Ponto inicial $x=2$

Derivada de $f(x) = f'(x) = 2x$

- Passo: $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \rightarrow$

- Iterações



1642 – 1727

Programação Não Linear

Método de Newton (ou Newton-Raphson)

- Exemplo: $f(x) = x^2$ | Vamos assumir Ponto inicial $x=2$


Derivada de $f(x) = f'(x) = 2x$

- Passo:
$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \rightarrow x_{k+1} = x_k - \frac{x_k^2}{2x_k}$$

- Iterações

$$x_1 = x_0 - \frac{x_0^2}{2x_0} = 2 - \frac{2^2}{2 \times 2} = 2 - 1 = 1$$

$$x_2 = ?$$



1642 – 1727



Programação Não Linear

Método de Newton (ou Newton-Raphson)

- Exemplo: $f(x) = x^2$ | Vamos assumir Ponto inicial $x=2$

Derivada de $f(x) = f'(x) = 2x$

- Passo:
$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \rightarrow x_{k+1} = x_k - \frac{x_k^2}{2x_k}$$

- Iterações


$$x_1 = x_0 - \frac{x_0^2}{2x_0} = 2 - \frac{2^2}{2 \times 2} = 2 - 1 = 1$$

$$x_2 = x_1 - \frac{x_1^2}{2x_1} = 1 - \frac{1^2}{2 \times 1} = 1 - 0.5 = 0.5$$

$$x_3 = ?$$

$$x_4 = ?$$

$$x_5 = ?$$





1642 – 1727



Programação Não Linear

Método de Newton (ou Newton-Raphson)



1642 – 1727

Exemplos interativo: <https://www.intmath.com/applications-differentiation/newtons-method-interactive.php>

Exemplos numéricos: <https://www.math24.net/newtons-method/>

Programação Não Linear

Método de Newton (ou Newton-Raphson)

- Exemplo Minimização: $f(x) = 4 + 8x^2 - x^4$ | Ponto inicial $x=3$

Derivada primeira $f'(x) = 0 + 8(2)x - 4x^3 = 16x - 4x^3$

Derivada segunda $f''(x) = 16 - 4(3)x^2 = 16 - 12x^2$

Equação 1


$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$
$$x_{k+1} = x_k - \frac{4 + 8x_k^2 - x_k^3}{16x_k - 4x_k^3}$$

$x_1 = 2,917 \dots$ $x_2 = 2,9107$
MÁXIMO

Equação 2 (Usando derivada 2ª)

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$
$$x_{k+1} = x_k - \frac{16x_k - 4x_k^3}{16 - 12x_k^2}$$

$x_1 = 2,347 \dots$ $x_4 = 2$
MÍNIMO



1642 – 1727

Programação Não Linear

Método de Newton (ou Newton-Raphson)

- N-Dimensões

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

← Vetor gradiente $\nabla f(x_k)$

← Matriz Hessiana $H[f(x_1, x_2, x_3, \dots, x_n)] =$
(n X n) das derivadas parciais de segunda ordem da função


$$x_{k+1} = x_k - H^{-1} \nabla f(x_k)$$

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

Programação Não Linear

Método Gradiente (Cauchy) x Método de Newton

- **Método de Cauchy:** lento, cauteloso. Tem garantia de convergência para soluções ótimas em condições muito gerais.
- **Método de Newton:** rápido, arrojado. Se for iniciado perto de uma solução ótima, pode ser excelente, mas pode divergir se partir de pontos ruins.
- **Métodos modernos:** “intermediários” entre os dois procurando unir as vantagens de ambos.



Gradiente
Newton