

Trabalho Prático 1

Redes completamente conectadas para reconhecimento de texturas mamográficas

Data de entrega: 20/10/2020 até às 10:30 pelo SGA

Valor: 30 pontos

Penalidade por atraso: Valor total, não se admite atraso!

Grupos: 2 ou 3 componentes

Descrição:


A densidade da mama é comprovadamente relacionada com o risco do desenvolvimento de câncer, uma vez que mulheres com uma maior densidade mamária podem esconder lesões, levando o câncer a ser detectado tardiamente. A escala de densidade chamada BIRADS foi desenvolvida pelo American College of Radiology e informa os radiologistas sobre a diminuição da sensibilidade do exame com o aumento da densidade da mama. BI-RADS definem a densidade como sendo quase inteiramente composta por gordura (densidade I), por tecido fibroproliferativo difuso (densidade II), por tecido denso heterogêneo (III) e por tecido extremamente denso (IV). A mamografia é a principal ferramenta de rastreio do câncer e radiologistas avaliam a densidade da mama com base na análise visual das imagens

Neste trabalho, você deverá implementar uma rede neural multicamadas (não convolucional) que receba como entrada uma imagem com resolução de 128x128 pixels e 8 bits por pixel e possibilite o reconhecimento automático da densidade da mama.


Exemplos de imagens com texturas típicas:



BIRADS I



BIRADS II



BIRADS III



BIRADS IV

Especificações do trabalho:

- O trabalho deve ser implementado em Python como notebooks jupyter, a partir das instruções contidas nos arquivos `trab1a.jpynb` e `trab1b.jpynb`.
- É permitido o uso de funções de bibliotecas para manipulação de imagens, mas o código das funções para implementação da rede deve ser original, seguindo as instruções dos notebooks.
- A base de dados deve ser lida de um diretório contendo 4 subdiretórios com os arquivos de imagens, associadas às 4 classes BIRADS. Os nomes dos subdiretórios serão 1,2,3 e 4. Essas imagens servirão para treinar e testar o classificador. O nome do diretório de entrada deve ser um parâmetro definido no início do código.
- A rede deve ser treinada utilizando no máximo 90% das imagens escolhidas de forma aleatória, mas balanceadas entre as classes. O uso de k-fold validation é incentivado.
- O restante das imagens deve ser usada para teste. O tempo de execução deve ser medido e exibido na interface, juntamente com a matriz de confusão e as métricas de sensibilidade média e especificidade média. Para 4 classes teremos a matriz de confusão 4×4 , M , onde a linha é a classe correta e a coluna a classe estimada. Dado um conjunto de treino com n imagens por classe, a sensibilidade média = acurácia = $\sum_{i=1..4} M_{i,i} / 4n$ e a especificidade = $1 - \sum_{i=1..4} \sum_{j \neq i} M_{j,i} / 12n$.
- O notebook deve conter a documentação do código, bem como a justificativa e análise de todos os hiperparâmetros e estratégias usados na concepção do classificador, incluindo o controle de overfitting, underfitting e velocidade de convergência. Incluir uma figura com a topologia da rede mais eficaz e uma comparação de resultados intermediários obtidos no processo de ajuste de hiperparâmetros. A nota será proporcional ao esforço empenhado no ajuste e qualidade da análise.

O que entregar:

Arquivos fontes, pacotes específicos e figuras incluídas no notebook. **NÃO INCLUIR AS IMAGENS!** Coloque todos os arquivos na raiz de um diretório cujo nome deve ser o número de matrícula de um dos componentes. Comprima o diretório e poste no SGA até a hora especificada. O tamanho total dos arquivos não deve ultrapassar 3 Mbytes.

Obs: Trabalhos de qualidade superior poderão ganhar pontos extras assim como o que obtiver as maiores taxas de acerto. **NÃO SÃO PERMITIDOS O USO OU DIVULGAÇÃO DAS IMAGENS FORNECIDAS, PARA OUTROS FINS, SEM AUTORIZAÇÃO PRÉVIA.**